UNIVERSITÉ HASSAN II DE CASABLANCA
FACULTÉ DES SCIENCES BEN M'SICK
DÉPARTEMENT DE MATHÉMATIQUES ET INFORMATIQUE
Filière : Master Big Data & Data Science (Niveau M1)

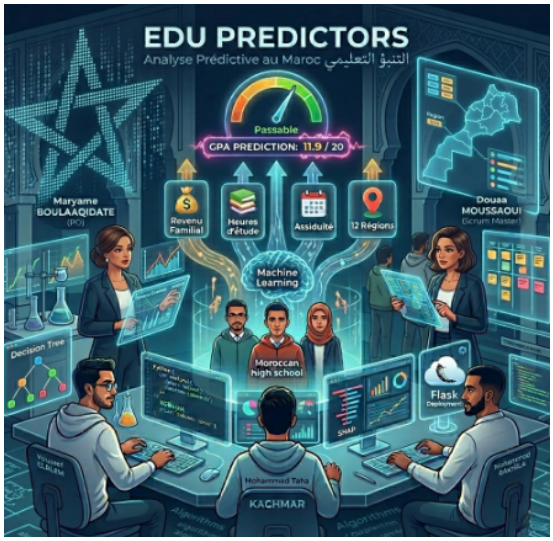

Rapport de Projet du module Python pour Data Science

Sujet : Prédiction de la Performance des Étudiants Marocains

Réalisé par :
Mlle. Maryame Boulaaqidate – Mlle. Douaa Moussaoui – Mr. Mohammed Taha Kachmar
Mr. Mohammed Rakhila – Mr. Youssef Elalem

Exposé le **25 février 2026** devant les membres du jury :

Pr. Said NOUH	Faculté des Sciences Ben M'Sick	Encadrant
M. Taoufik AMZIL	Faculté des Sciences Ben M'Sick	Co-Encadrant

Année Universitaire : 2025 – 2026

Dédicaces

À nos chers parents,
Pour leur amour inconditionnel, leurs prières et leurs sacrifices qui nous ont permis d'atteindre ce niveau d'études au sein du Master Big Data & Data Science à la Faculté des Sciences Ben M'SICK.

À nos professeurs et encadrants,
Particulièrement Pr. Said Nouh et M. Taoufik Amzil, pour nous avoir transmis leur savoir et pour leur accompagnement précieux durant ce module.

À nos amis et collègues du Master Big Data & Data Science, pour les moments de partage et d'entraide durant cette année universitaire 2025-2026.

Remerciements

Nous tenons tout d'abord à exprimer notre profonde gratitude à nos encadrants, **Pr. Said NOUH** et **M. Taoufik AMZIL**. Nous les remercions pour leur disponibilité, leur patience et la qualité de l'encadrement dont ils nous ont fait bénéficier tout au long de ce projet de science des données.

Nos remerciements s'adressent également au corps professoral et administratif de la **Faculté des Sciences Ben M'Sick (FSBM)**, particulièrement aux responsables du Master Big Data & Data Science. Merci de nous avoir fourni le cadre pédagogique et technique nécessaire pour développer des solutions innovantes comme **EduPredictors**.

Enfin, nous remercions les membres du jury pour l'intérêt qu'ils portent à notre travail et pour avoir accepté d'évaluer cet exposé du 25 février 2026.

Table des matières

Dédicaces **1**

Remerciements **2**

Liste des Abréviations **6**

1 Introduction générale et contexte du projet **7**
1.1 Contexte du Projet 7

2 Problématique et analyse des besoins (cahier des charges) **8**
2.1 Problématique 8
2.2 Analyse des Besoins (Cahier des Charges) 8
2.2.1 Besoins Fonctionnels 8
2.2.2 Besoins Techniques 9
2.2.3 Besoins en Gestion de Projet 9
2.3 Objectifs du Projet 9

3 Présentation de l'état de l'art en brefs des travaux antérieurs sur le sujet **10**

4 Modèles machine Learning utilisés et description des jeux de données utilisés **11**
4.1 Description des Jeux de Données Utilisés 11
4.1.1 Analyse Exploratoire des Données (EDA) 11
4.2 Modèles de Machine Learning Utilisés 15

5 Programme python utilisé **16**
5.1 Pipeline de données et Préparation 16
5.2 Feature Engineering 16
5.3 Serveur et Déploiement : L'API Flask 17

6 Optimisation du modèle via PyCaret et TPOT (Optionnel) **18**

7 Résultats **19**
7.1 Tableau Comparatif des Performances 19
7.2 Interprétation des Résultats 24
7.3 Résultats via l'Interface Web et Application 25
7.3.1 L'interface Web de prédiction 25
7.3.2 Captures d'écran de l'Application Mobile 26

8 Conclusion générale et perspectives **32**
8.1 Bilan du Projet 32

8.2 Perspectives d'Avenir 32

Table des figures

4.1 Distribution de la moyenne annuelle et répartition des niveaux de risque. . 12
4.2 Boxplots des variables numériques clés pour la détection des valeurs aberrantes. 12
4.3 Distribution des principales variables catégorielles (sexe, type d'établissement, région, profession du père). 13
4.4 Matrice de corrélation — Top 15 des variables les plus corrélées avec la moyenne annuelle. 14
4.5 Analyse bivariée : impact des absences sur la note et heures d'étude par niveau de risque. 14

5.1 Distribution de la variable cible (moyenne annuelle) après nettoyage des valeurs aberrantes. 17

7.1 Comparaison graphique des 8 modèles : R^2 (Train vs Test), RMSE et MAE. 20
7.2 Analyse des résidus du meilleur modèle : résidus vs prédictions, distribution des résidus et valeurs réelles vs prédites. 20
7.3 Top 20 des variables les plus importantes selon Random Forest et XGBoost. 20
7.4 Validation Curves pour le diagnostic d'overfitting/underfitting (Ridge, Random Forest, XGBoost). 21
7.5 SHAP Values — Contribution de chaque feature aux prédictions du modèle XGBoost. 22
7.6 SHAP Feature Importance — Importance moyenne absolue de chaque feature. 23
7.7 Courbes d'apprentissage des 4 modèles clés (ElasticNet, Random Forest, Gradient Boosting, XGBoost). 24
7.8 Page d'accueil de l'interface web EduPredictors avec statistiques et pipeline. 25
7.9 Formulaire de prédiction et jauge de résultat sur l'interface web. 26
7.10 Écran d'accueil de l'application mobile EduPredictors. 26
7.11 Formulaire de création de compte sur l'application mobile. 27
7.12 Page de connexion sécurisée de l'application mobile. 27
7.13 Menu principal et tableau de bord de l'application mobile. 28
7.14 Saisie des données personnelles de l'étudiant sur l'application mobile. . . . 28
7.15 Saisie des informations familiales sur l'application mobile. 29
7.16 Saisie des données académiques et scolaires sur l'application mobile. 29
7.17 Validation du formulaire avant soumission sur l'application mobile. 30
7.18 Écran de chargement pendant l'analyse par l'API Flask sur l'application mobile. 30
7.19 Affichage du résultat de la prédiction via la jauge de performance. 31
7.20 Page de recommandations personnalisées en fonction du score prédit. . . . 31

Liste des tableaux

7.1 Comparaison des performances des 8 modèles (69 features). 19

Liste des Abréviations

API	Application Programming Interface
EDA	Exploratory Data Analysis
MAE	Mean Absolute Error
ML	Machine Learning
MLP	Multi-Layer Perceptron
R^2	Coefficient de détermination
RMSE	Root Mean Square Error
SHAP	Shapley Additive Explanations

Chapitre 1

Introduction générale et contexte du projet

Le système éducatif marocain traverse une période charnière où la réussite des élèves est confrontée à des obstacles structurels majeurs. Malgré les efforts de réforme, le taux de décrochage scolaire demeure préoccupant, souvent exacerbé par des disparités régionales marquées et des inégalités socio-économiques profondes. Face à ces constats, le projet **EduPredictors** propose une approche basée sur la science des données pour transformer des indicateurs socio-démographiques en leviers d'action pédagogique.

1.1 Contexte du Projet

L'enjeu majeur de ce projet est de passer d'un simple constat d'échec à une véritable logique de **prévention active**. Actuellement, les interventions pédagogiques surviennent souvent trop tard, une fois que l'élève est déjà en situation de rupture scolaire.

Avant d'aborder le développement du projet, voici un rappel des concepts clés utilisés dans cette étude :

- **Machine Learning :** Une approche scientifique consistant à transformer des indicateurs bruts en prédictions actionnables via des modèles mathématiques capables d'apprendre des données.
- **Scrum & JIRA :** Méthodologie agile structurant le projet en cycles itératifs appelés « Sprints » avec l'outil de gestion JIRA.

Chapitre 2

Problématique et analyse des besoins (cahier des charges)

2.1 Problématique

Le système éducatif marocain se trouve actuellement à une période charnière où la réussite des apprenants se heurte à des obstacles structurels majeurs. Malgré les réformes successives, le taux de décrochage scolaire reste préoccupant, alimenté par des disparités régionales et des inégalités socio-économiques profondes.

Question de recherche

Comment prédire la moyenne annuelle d'un lycéen marocain à partir de ses caractéristiques socio-démographiques, académiques et comportementales en utilisant le Machine Learning ?
L'objectif final est de pouvoir intervenir tôt, **avant** que l'échec ne se produise.

2.2 Analyse des Besoins (Cahier des Charges)

Pour répondre à cette problématique, notre équipe a structuré le projet autour d'un cahier des charges :

2.2.1 Besoins Fonctionnels

- **Traitement de données massives :** Analyse d'un jeu de données représentatif de **10 000 étudiants** répartis sur les 12 régions du Maroc.
- **Ingénierie des caractéristiques :** Sélection de **35 variables** d'entrée parmi 286 indicateurs initiaux, enrichies par un Feature Engineering avancé pour obtenir **69 features** au total.
- **Modélisation prédictive :** Comparaison de **8 algorithmes** de Machine Learning et sélection du meilleur modèle (Gradient Boosting Tuné), capable de capturer des relations complexes et non-linéaires.
- **Aide à la décision :** Fournir aux établissements des outils *data-driven* pour identifier les élèves à risque.

2.2.2 Besoins Techniques

L'architecture de la solution doit reposer sur un socle technologique robuste :

- **Backend :** API Flask en Python pour charger et servir le modèle sérialisé (.pkl).
- **Frontend :** Interface utilisateur de type Single Page App avec un design moderne Glassmorphisme.
- **Déploiement :** Hébergement de la solution sur la plateforme Render Cloud.

2.2.3 Besoins en Gestion de Projet

- **Méthodologie et Outils :** Utilisation du cadre Scrum avec des cycles itératifs (Sprints) et gestion du Backlog via l'outil JIRA.
- **Rôles :** Organisation claire entre le Product Owner, le Scrum Master et la Dev Team.

2.3 Objectifs du Projet

Ce dispositif vise à fournir aux établissements scolaires des outils de décision (*Data-Driven*). En identifiant les élèves à risque, **EduPredictors** participe à une vision moderne de l'éducation où le numérique sert l'équité des chances.

Chapitre 3

Présentation de l'état de l'art en brefs des travaux antérieurs sur le sujet

La prédiction de la performance académique est un domaine de recherche actif dans la littérature éducative et informatique. Diverses études antérieures ont exploité le Machine Learning pour anticiper le succès ou l'échec des apprenants.

Généralement, on retrouve l'utilisation d'algorithmes tels que les Arbres de Décision, les Forêts Aléatoires (Random Forest) ou les Réseaux de Neurones. Les travaux soulignent fréquemment l'importance prépondérante des facteurs socio-économiques et comportementaux par rapport aux simples notes antérieures. Notre projet s'inscrit dans la continuité de ces recherches en appliquant des algorithmes de boosting de gradient (Gradient Boosting, XGBoost), connus pour leurs performances supérieures sur des données tabulaires, spécifiquement adaptés au contexte éducatif et démographique marocain.

Chapitre 4

Modèles machine Learning utilisés et description des jeux de données utilisés

4.1 Description des Jeux de Données Utilisés

Le projet repose sur l'analyse de **10 000 profils** d'étudiants répartis sur les 12 régions du Maroc :

- **Variables initiales :** 286 variables au total.
- **Features d'entrée retenues :** 35 variables clés (17 numériques et 18 catégorielles) sélectionnées après nettoyage et analyse exploratoire.
- **Feature Engineering :** Création de 7 variables calculées (revenu par personne, ratio étude/écran, indice de discipline, etc.) portant le total à **69 features** après encodage One-Hot.
- **Indicateurs Déterminants :** Heures d'étude, revenu familial, absentéisme, taux d'assiduité, motivation et comportement.
- **Partitionnement :** Le jeu de données a été partitionné selon un ratio de 80% pour l'entraînement (8 000 échantillons) et 20% pour le test (2 000 échantillons).

Insight majeur de l'EDA

L'analyse exploratoire a révélé que le **revenu familial** est la variable la plus corrélée positivement avec la performance académique ($r = +0.37$).

4.1.1 Analyse Exploratoire des Données (EDA)

L'analyse exploratoire approfondie a permis de comprendre la structure et les caractéristiques du jeu de données avant la modélisation.

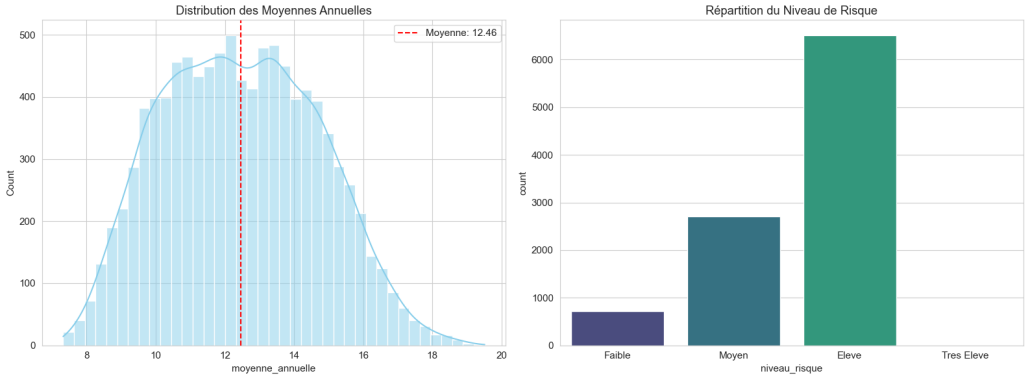

Figure 4.1 – *Distribution de la moyenne annuelle et répartition des niveaux de risque.*

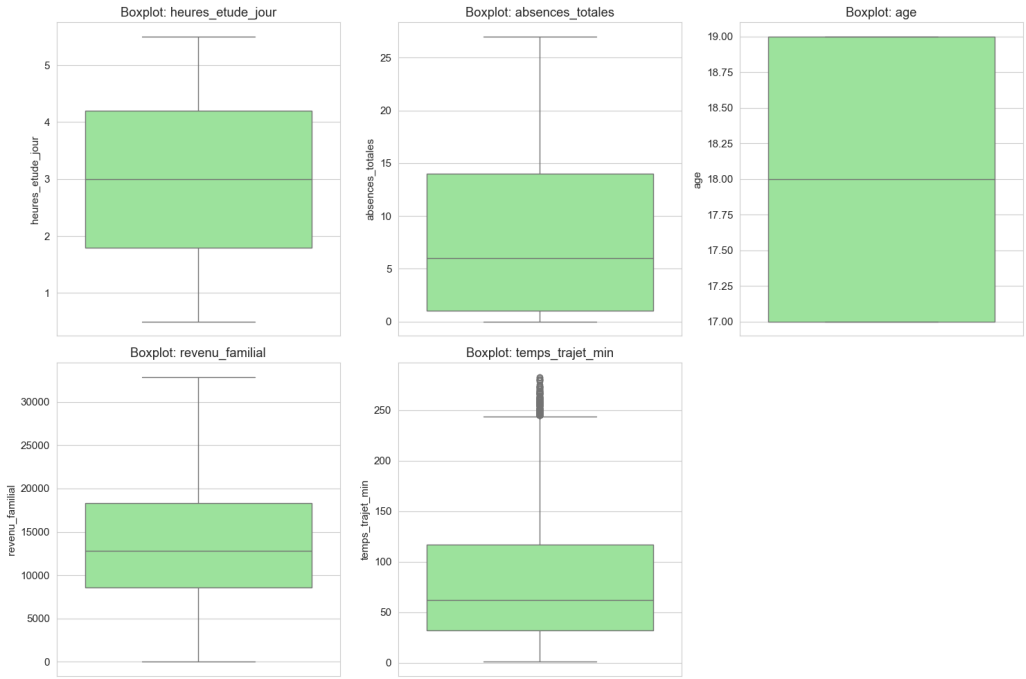

Figure 4.2 – *Boxplots des variables numériques clés pour la détection des valeurs aberrantes.*

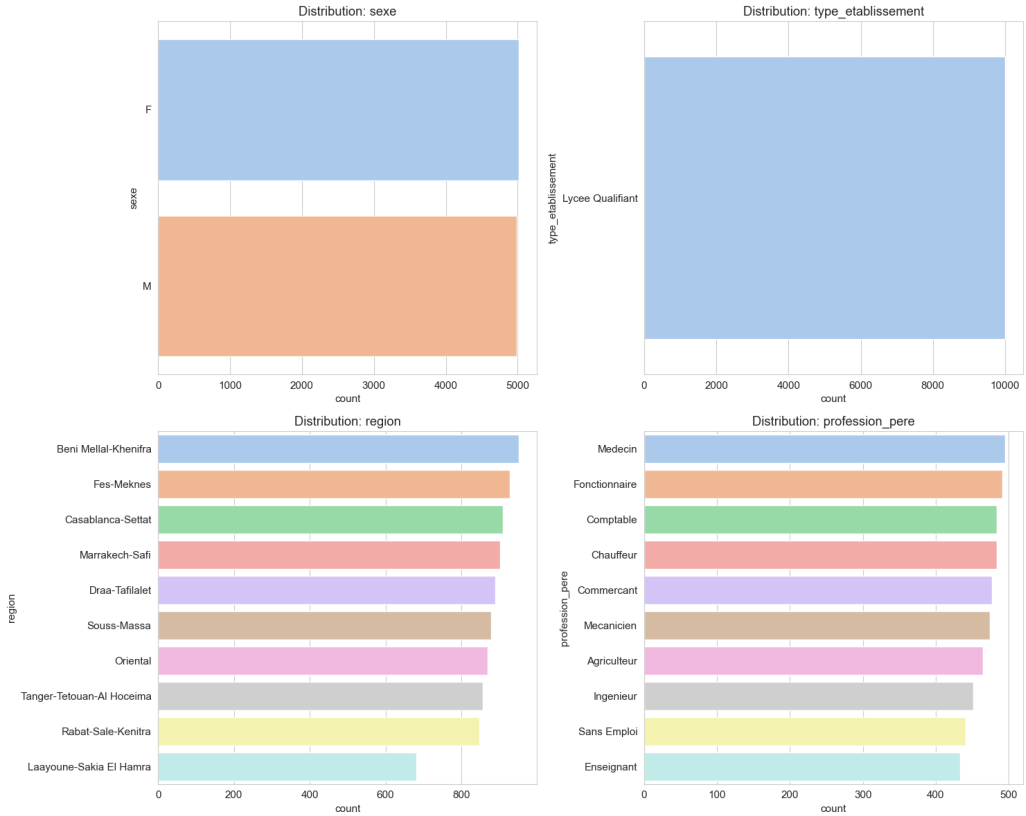

Figure 4.3 – *Distribution des principales variables catégorielles (sexe, type d'établissement, région, profession du père).*

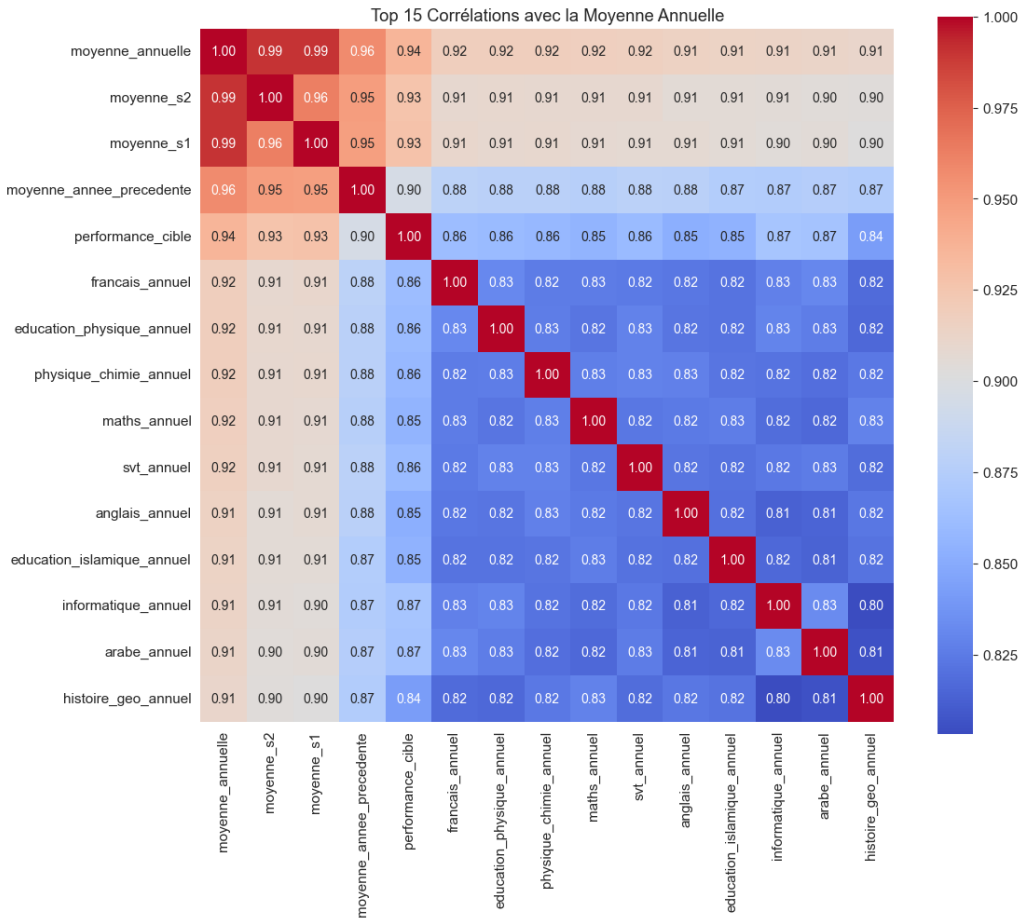

Figure 4.4 – *Matrice de corrélation — Top 15 des variables les plus corrélées avec la moyenne annuelle.*

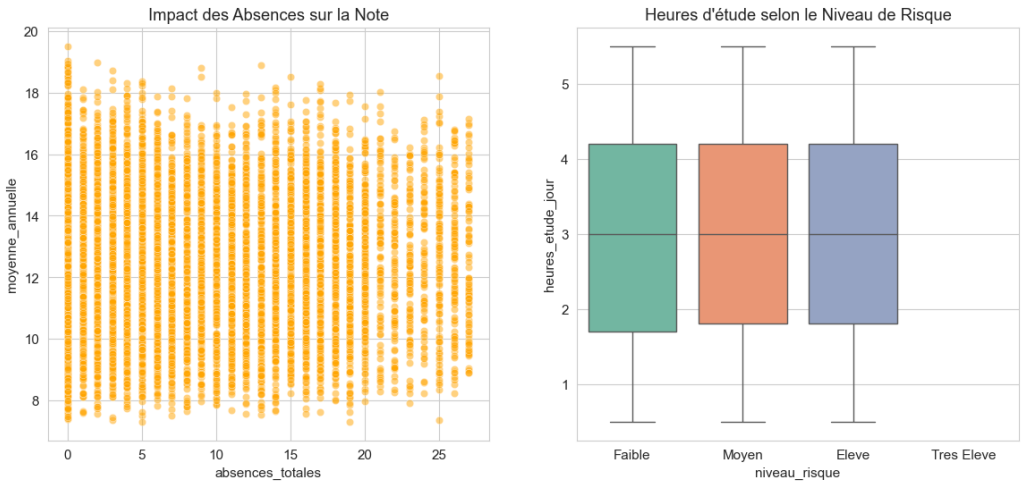

Figure 4.5 – *Analyse bivariée : impact des absences sur la note et heures d'étude par niveau de risque.*

4.2 Modèles de Machine Learning Utilisés

Pour garantir la robustesse de la prédiction, **huit modèles** ont été mis en compétition :

- **Régression Linéaire (Baseline) :** Pour cibler les relations directes et proportionnelles entre les features et la variable cible.
- **Ridge (L2) :** Régularisation L2 pour prévenir le surapprentissage en pénalisant les coefficients trop élevés.
- **Lasso (L1) :** Régularisation L1 qui permet d'éliminer automatiquement les features peu pertinentes en forçant certains coefficients à zéro.
- **ElasticNet (L1+L2) :** Combinaison des régularisations L1 et L2, offrant un équilibre entre sélection de variables et stabilité.
- **Random Forest :** Un algorithme d'ensemble combinant plusieurs arbres de décision avec échantillonnage aléatoire (bagging).
- **Gradient Boosting (Tuné) :** Algorithme de boosting de gradient optimisé par `RandomizedSearchCV`, qui construit séquentiellement des arbres faibles pour corriger les erreurs résiduelles.
- **XGBoost :** Implémentation optimisée du boosting de gradient avec régularisation intégrée et gestion native des valeurs manquantes.
- **Deep Learning (MLP) :** Un réseau de neurones multicouches (Multi-Layer Perceptron) modélisant des schémas non-linéaires complexes.

Le choix final s'est porté sur le modèle **Gradient Boosting Tuné**, qui a obtenu les meilleures performances sur l'ensemble de test avec un R^2 de **0,9285**.

Chapitre 5

Programme python utilisé

5.1 Pipeline de données et Préparation

Le programme Python utilise la bibliothèque `scikit-learn` pour le traitement des données. Le pipeline de données intègre un `ColumnTransformer` incluant un `StandardScaler` pour normaliser les 30 variables numériques, et un `OneHotEncoder` pour coder les 34 variables catégorielles. Ceci garantit que les algorithmes fonctionnent de manière optimale indépendamment des échelles de mesure.

5.2 Feature Engineering

Une étape clé du projet a consisté à créer des **variables calculées** à partir des 35 features d'entrée, afin d'enrichir le pouvoir prédictif du modèle. Sept nouvelles variables ont été ingéniérées :

- **Revenu par personne :** *revenu_familial* ÷ *nombre_membres_famille* — mesure le pouvoir d'achat réel par membre du foyer.
- **Ratio étude/écran :** Rapport entre le temps total d'étude hebdomadaire et le temps d'écran, quantifiant l'équilibre entre effort et distraction.
- **Indice de discipline :** Moyenne des taux d'assiduité, de ponctualité et de remise des devoirs.
- **Pénalité de comportement :** Somme des absences totales et des retards.
- **Charge parascolaire :** Somme des heures de soutien et d'activité physique par semaine.
- **Score numérique :** Nombre de ressources numériques disponibles (internet, ordinateur portable, chambre personnelle).
- **Ratio repos/activité :** Rapport entre les heures de sommeil et le temps total d'étude.

Ces variables calculées, combinées à l'encodage One-Hot des catégories, portent le nombre total de features à **69**.

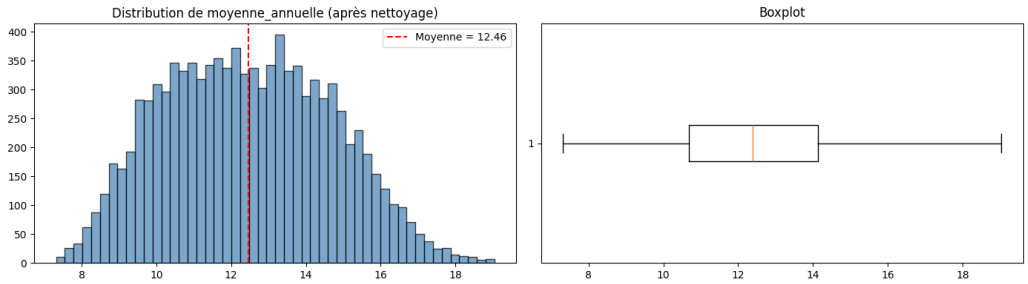

Figure 5.1 – *Distribution de la variable cible (moyenne annuelle) après nettoyage des valeurs aberrantes.*

5.3 Serveur et Déploiement : L'API Flask

Une API **Flask** a été développée en Python pour créer une interface de communication entre notre modèle prédictif et l'application web finale. Le modèle retenu (Gradient Boosting Tuné) a été sérialisé et enregistré au format `.pkl` via `joblib`, ce qui permet à l'application web de le charger en mémoire au démarrage et d'effectuer des prédictions en temps réel. L'API reçoit les données saisies par l'utilisateur sous forme de requête JSON via l'endpoint `/predict`, applique le Feature Engineering, puis retourne la note prédite sur 20.

Le déploiement est effectué sur **Render Cloud** avec `gunicorn` comme serveur WSGI de production.

Chapitre 6

Optimisation du modèle via PyCaret et TPOT (Optionnel)

Afin d'automatiser et de conforter nos choix d'algorithmes, nous pouvons utiliser des outils d'AutoML tels que **PyCaret** ou **TPOT**. Ces bibliothèques Python permettent d'explorer en quelques lignes de code des dizaines de modèles, d'optimiser leurs hyperparamètres par des approches génétiques (TPOT) ou bayésiennes, et de comparer automatiquement les métriques de performance. Bien que le réglage du Gradient Boosting ait été fait par `RandomizedSearchCV` dans notre cas principal, ces outils optionnels valident la supériorité des arbres boostés pour ce type de données tabulaires.

Chapitre 7

Résultats

7.1 Tableau Comparatif des Performances

Le modèle **Gradient Boosting Tuné** s'est imposé comme le meilleur prédicteur ($R^2 =$ 0,9285) grâce à sa capacité à capturer les relations non-linéaires entre les 69 features et la moyenne annuelle. Ce score élevé signifie que le modèle explique environ **92,85%** de la variance de la performance des étudiants.

L'interprétabilité via les SHAP Values confirme que la réussite est déterminée par un mélange de moyens (revenu familial, ressources numériques) et d'efforts (heures d'étude, assiduité, ponctualité). Le Feature Engineering a joué un rôle clé dans l'amélioration significative des performances par rapport aux modèles entraînés sur les variables brutes uniquement.

Modèle	R^2 Test	RMSE	MAE
Régression Linéaire	0,9265	0,603	0,478
Ridge (L2)	0,9265	0,603	0,478
Lasso (L1)	0,9262	0,604	0,479
ElasticNet (L1+L2)	0,9262	0,604	0,479
Random Forest	0,7148	1,189	0,933
★ Gradient Boosting (Tuné)	**0,9285**	**0,595**	**0,472**
XGBoost	0,9271	0,600	0,476
Deep Learning (MLP)	0,9224	0,620	0,492

Table 7.1 – *Comparaison des performances des 8 modèles (69 features).*

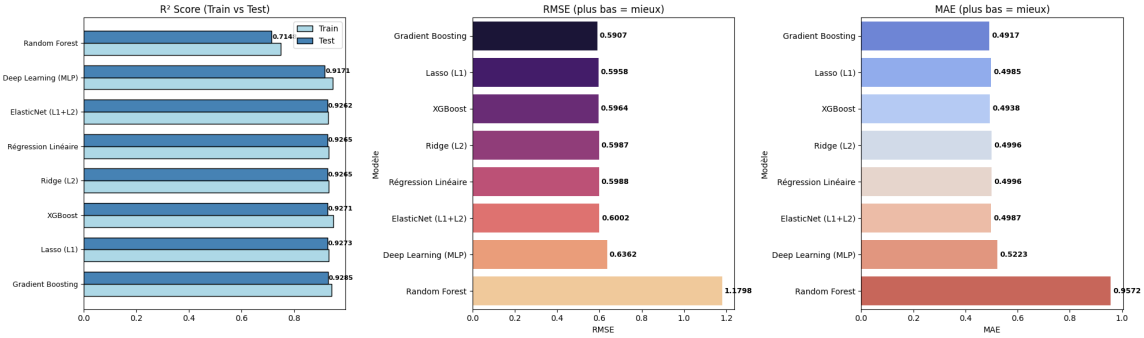

Figure 7.1 – *Comparaison graphique des 8 modèles : R^2 (Train vs Test), RMSE et MAE.*

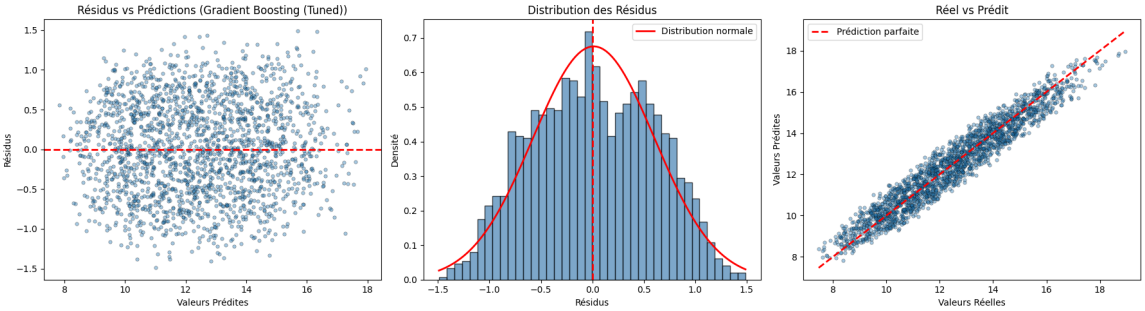

Figure 7.2 – *Analyse des résidus du meilleur modèle : résidus vs prédictions, distribution des résidus et valeurs réelles vs prédites.*

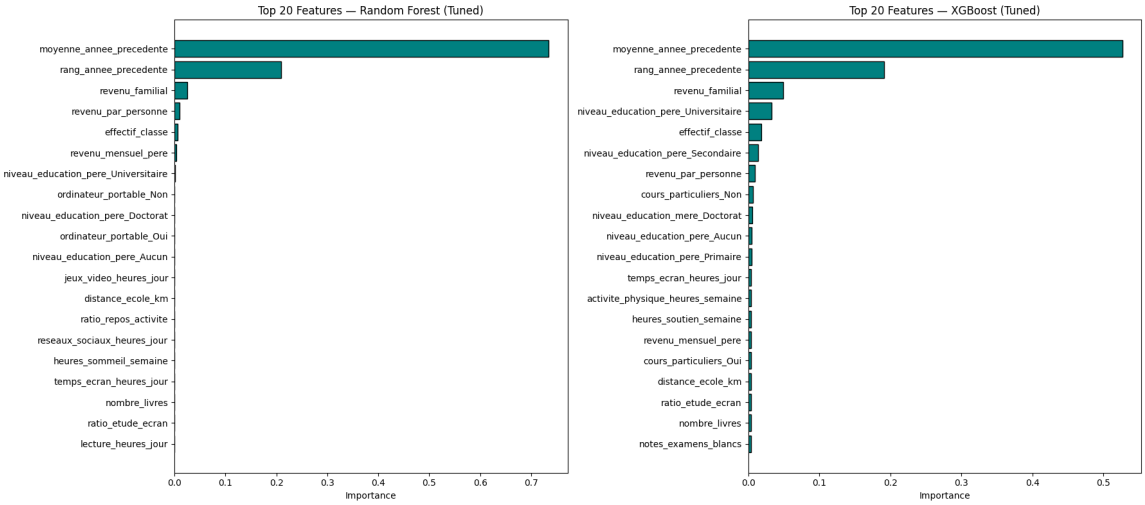

Figure 7.3 – *Top 20 des variables les plus importantes selon Random Forest et XGBoost.*

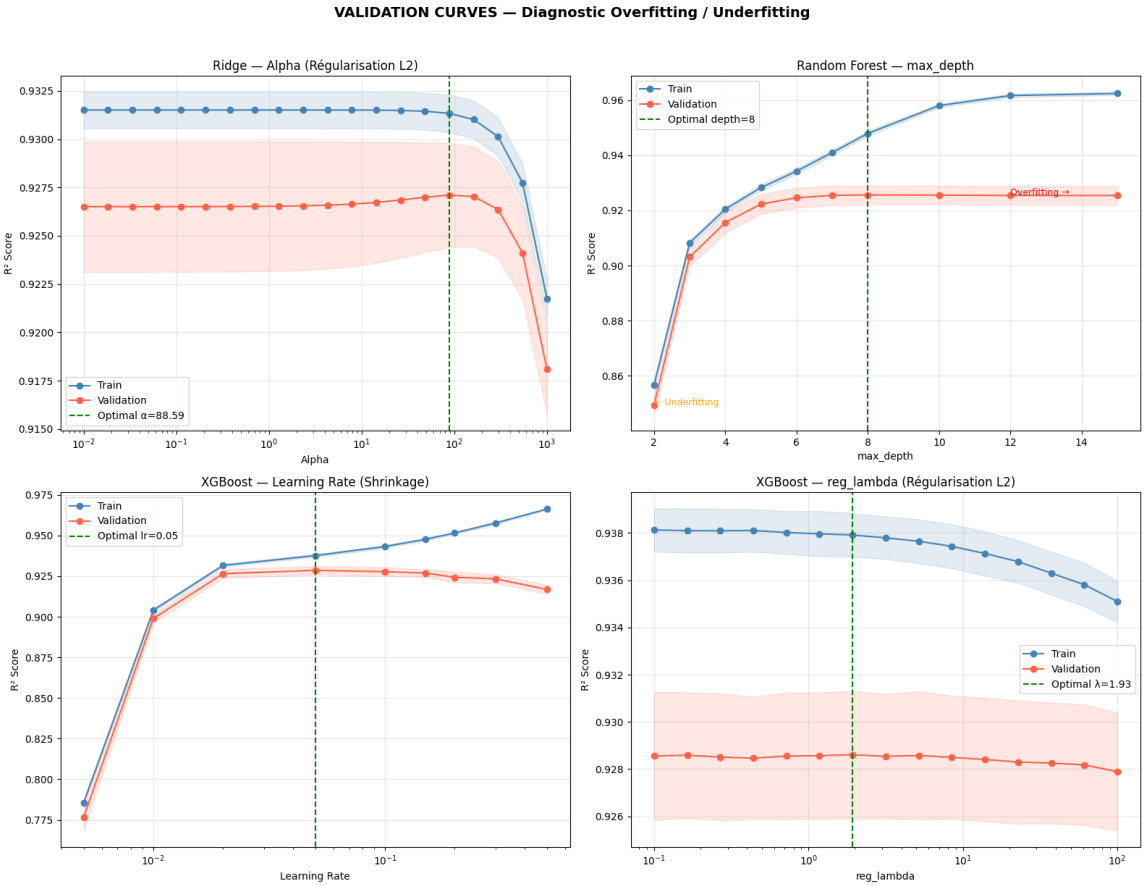

Figure 7.4 – *Validation Curves pour le diagnostic d'overfitting/underfitting (Ridge, Random Forest, XGBoost).*

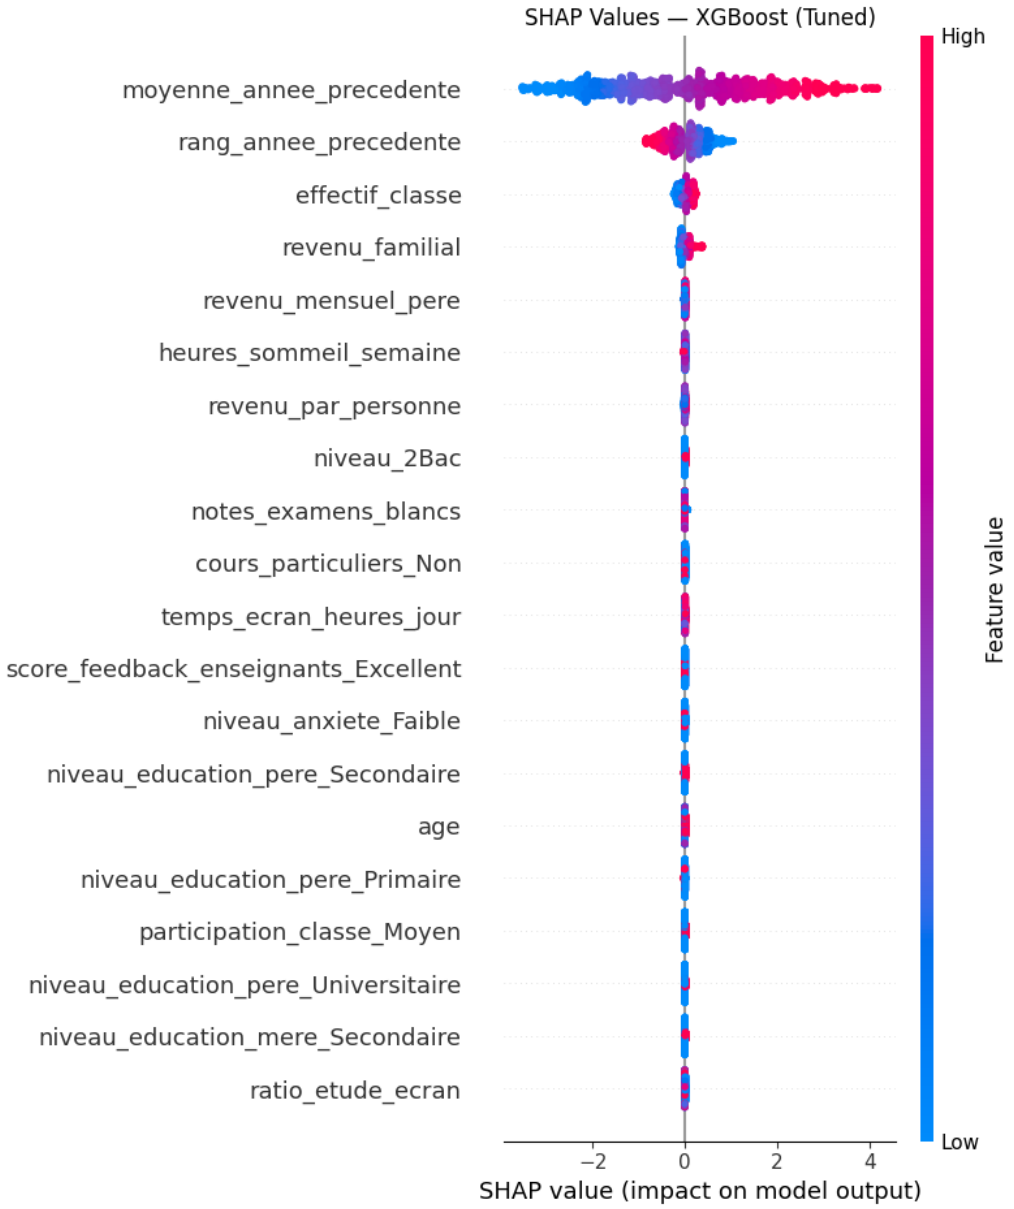

Figure 7.5 – *SHAP Values — Contribution de chaque feature aux prédictions du modèle XGBoost.*

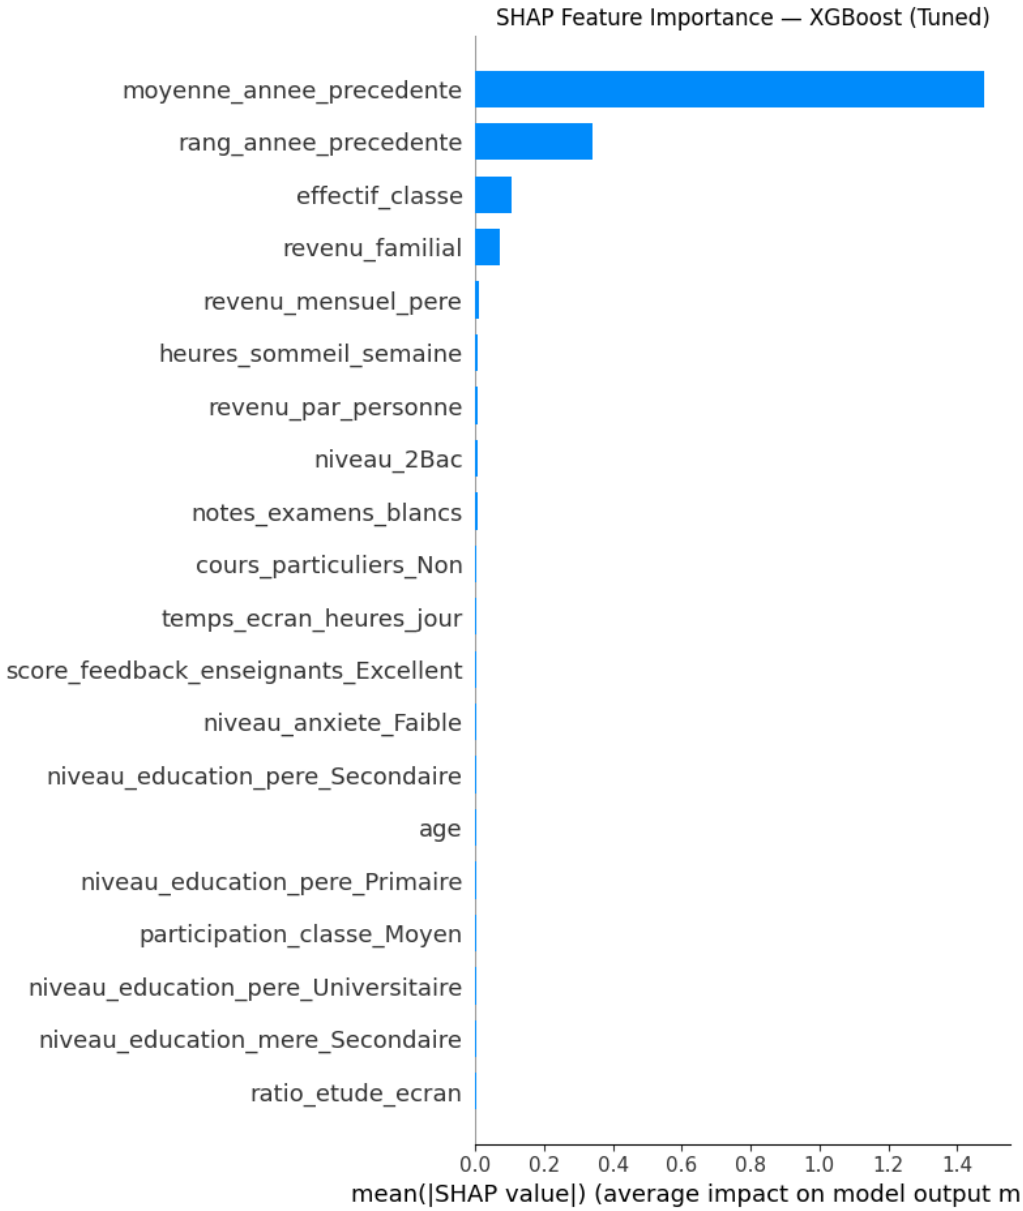

Figure 7.6 – *SHAP Feature Importance — Importance moyenne absolue de chaque feature.*

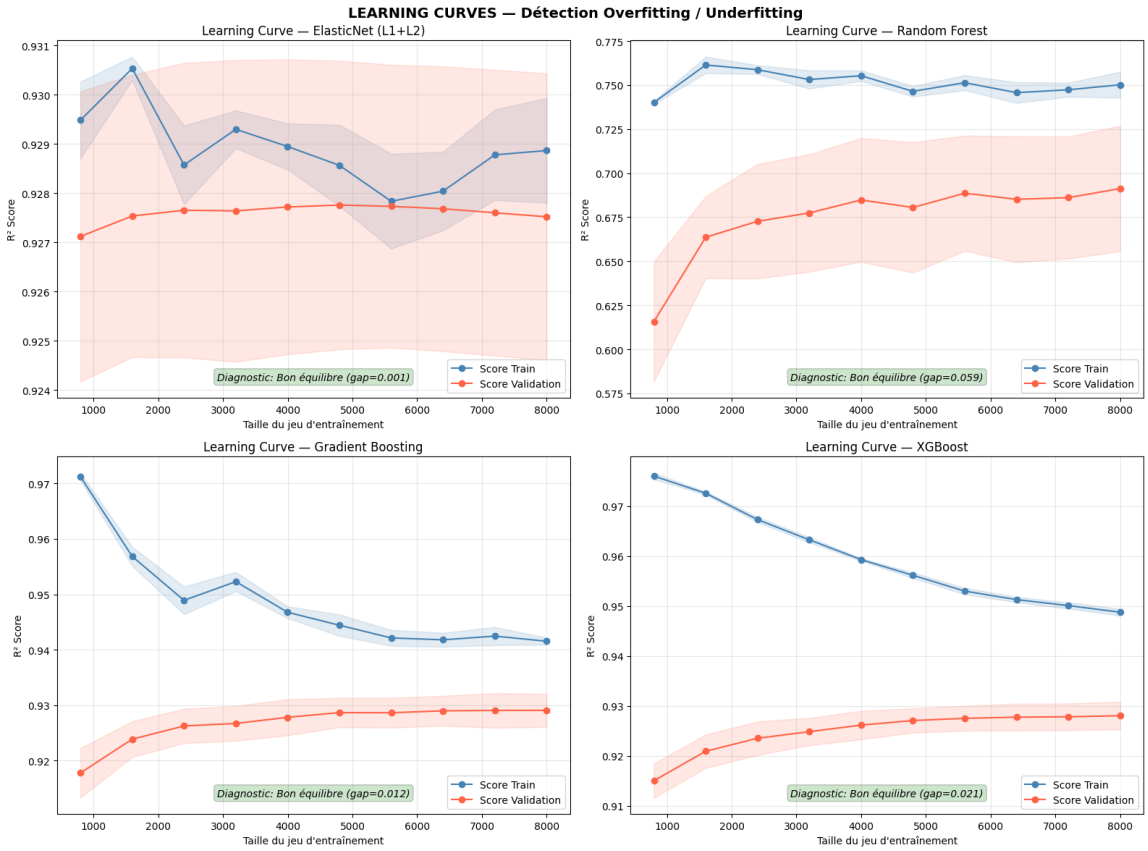

Figure 7.7 – *Courbes d'apprentissage des 4 modèles clés (ElasticNet, Random Forest, Gradient Boosting, XGBoost).*

7.2 Interprétation des Résultats

- **Supériorité du Gradient Boosting Tuné :** Avec un R^2 de **0,9285**, le RMSE le plus bas (**0,595**) et le MAE le plus bas (**0,472**), ce modèle surpasse tous les autres algorithmes testés. Il capture efficacement les relations non-linéaires grâce à l'optimisation de ses hyperparamètres via `RandomizedSearchCV`.
- **Proximité des modèles linéaires :** La Régression Linéaire, le Ridge, le Lasso et l'ElasticNet affichent tous des performances très proches ($R^2 \approx 0{,}926$), indiquant qu'une grande partie de la relation est linéaire, mais les gains supplémentaires proviennent de la capture des non-linéarités.
- **Random Forest en retrait :** Avec un R^2 de seulement **0,7148**, le Random Forest montre un surapprentissage ou une difficulté à généraliser sur ces données, malgré sa nature d'ensemble.
- **XGBoost compétitif :** Le XGBoost ($R^2 = 0{,}9271$) se place très près du Gradient Boosting Tuné, confirmant la pertinence des algorithmes de boosting pour ce problème.
- **Deep Learning (MLP) :** Le réseau de neurones ($R^2 = 0{,}9224$) reste performant mais légèrement en dessous des méthodes de boosting, ce qui est courant sur des données tabulaires de taille modérée.

7.3 Résultats via l'Interface Web et Application

7.3.1 L'interface Web de prédiction

L'interface web de l'application EduPredictors, conçue avec un design moderne *Glassmorphisme* sur fond sombre, offre une expérience utilisateur fluide. L'interface est structurée en plusieurs sections :

- **Page d'accueil (Hero) :** Présentation du projet avec des statistiques clés (10 000 étudiants, 69 features, 8 modèles, 12 régions) et accès direct à la prédiction.
- **Pipeline Data Science :** Visualisation interactive des 6 étapes du processus (collecte, nettoyage, EDA, modélisation, évaluation, déploiement).
- **Formulaire de prédiction :** Organisé en 5 onglets thématiques (Personnel, Famille, Scolarité, Mode de Vie, Comportement) pour la saisie des 35 variables d'entrée.
- **Jauge de performance :** Une visualisation graphique SVG circulaire avec dégradé de couleurs (rouge → jaune → vert) qui transforme la sortie du modèle en note sur 20.
- **Feedback contextuel :** Interprète le score avec une mention et un code couleur (Excellent, Bien, Passable, Insuffisant).

Figure 7.8 – *Page d'accueil de l'interface web EduPredictors avec statistiques et pipeline.*

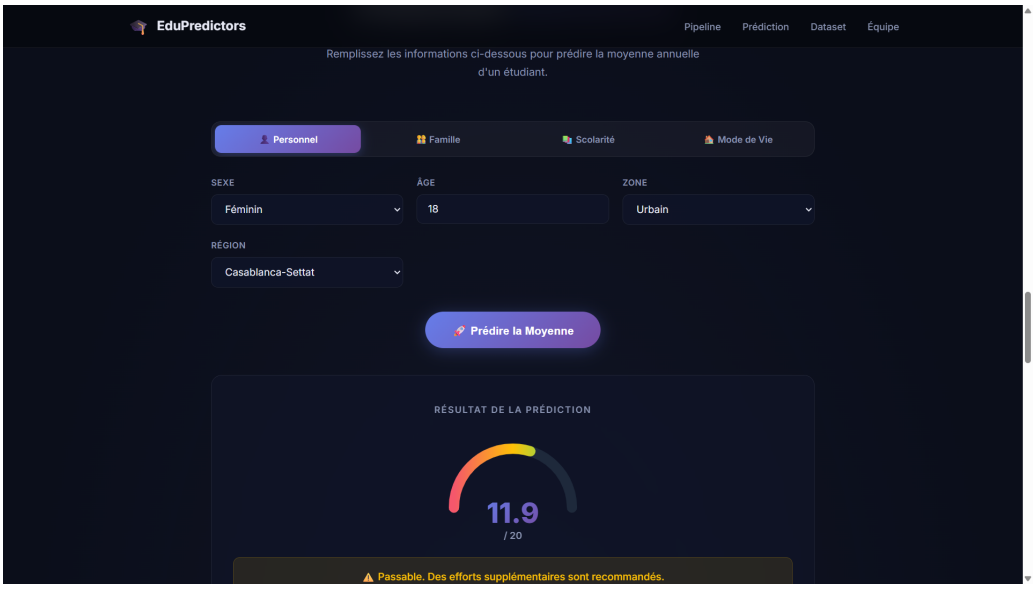

Figure 7.9 – *Formulaire de prédiction et jauge de résultat sur l'interface web.*

Une démonstration concrète sur l'interface montre qu'en saisissant un **revenu familial de 20 000 MAD** avec un soutien familial *Moyen*, le modèle Gradient Boosting prédit une **moyenne de 14.1/20**. En abaissant ce revenu, la prédiction chute significativement, ce qui confirme l'influence prépondérante des facteurs socio-économiques identifiée par l'analyse SHAP.

7.3.2 Captures d'écran de l'Application Mobile

Cette section présente les différentes interfaces de l'application mobile EduPredictors, illustrant le parcours utilisateur complet.

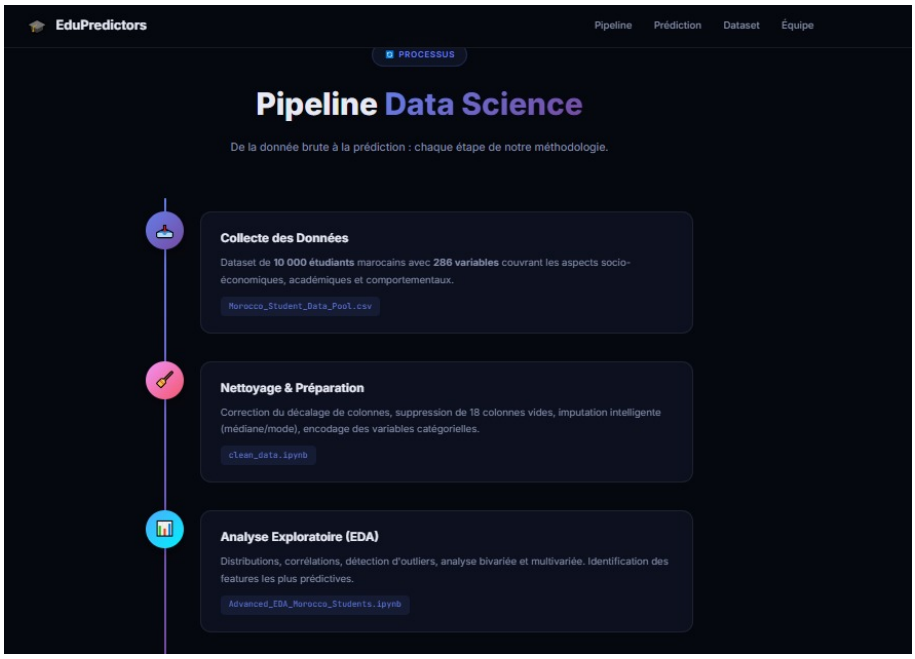

Figure 7.10 – *Écran d'accueil de l'application mobile EduPredictors.*

Figure 7.11 – *Formulaire de création de compte sur l'application mobile.*

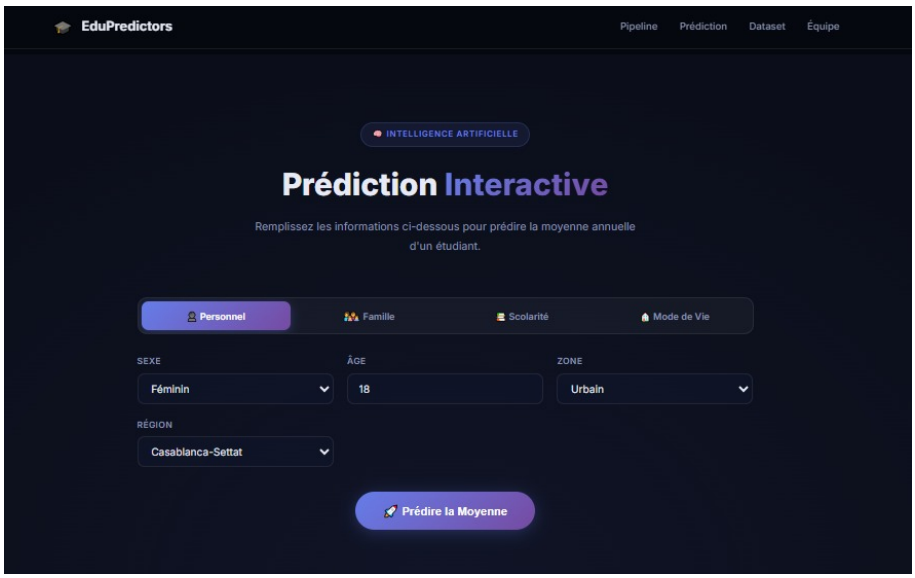

Figure 7.12 – *Page de connexion sécurisée de l'application mobile.*

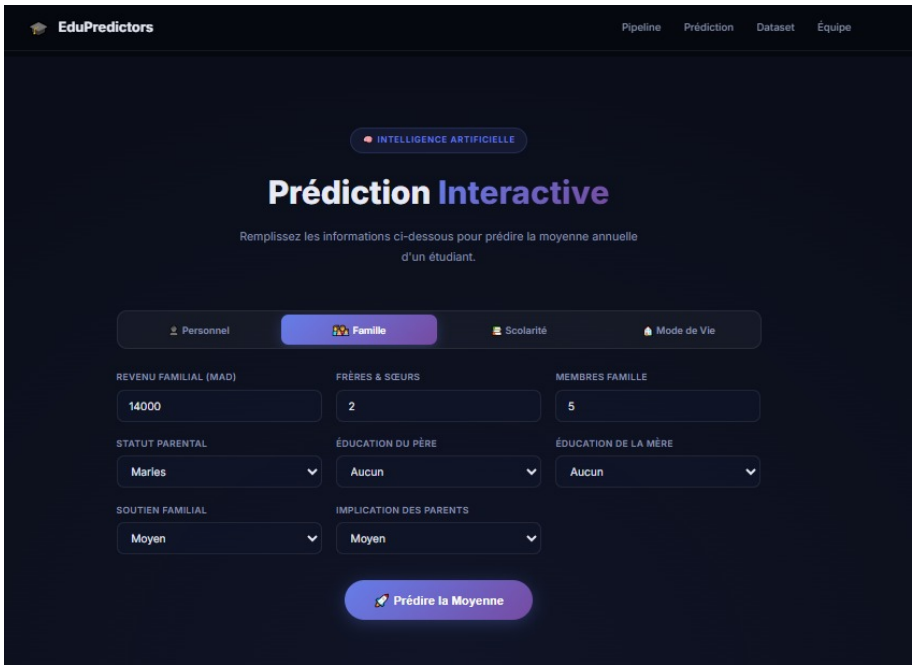

Figure 7.13 – *Menu principal et tableau de bord de l'application mobile.*

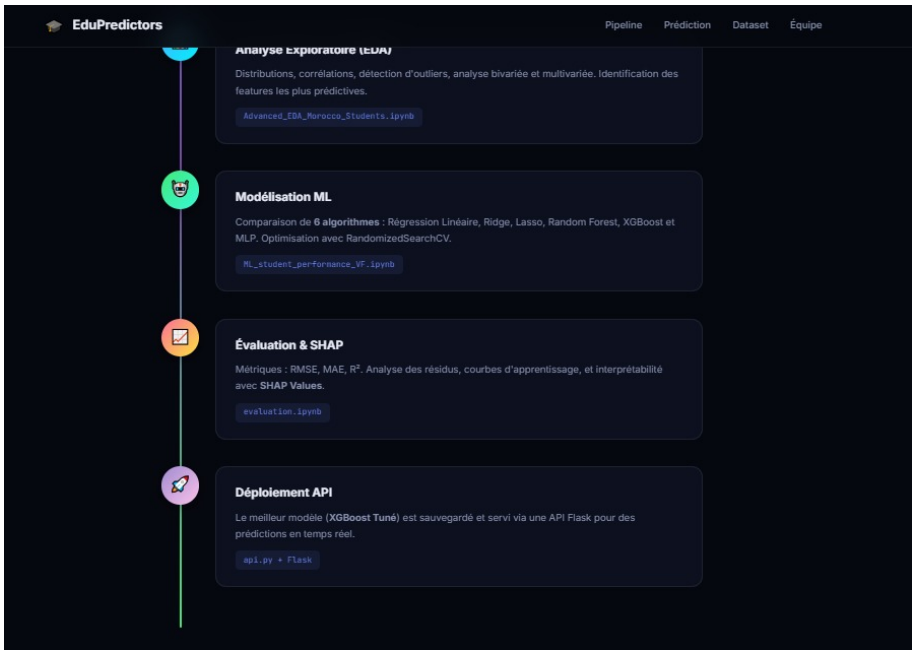

Figure 7.14 – *Saisie des données personnelles de l'étudiant sur l'application mobile.*

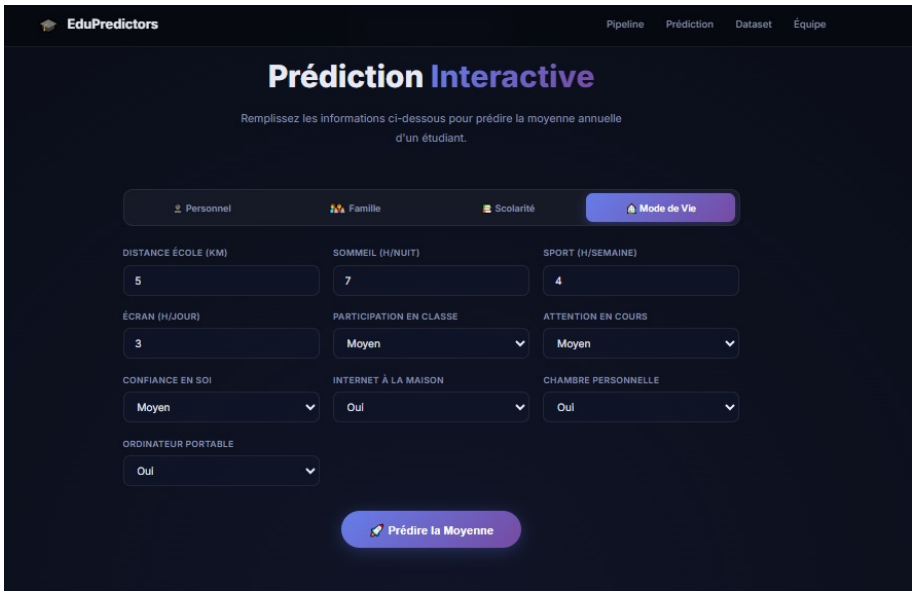

Figure 7.15 – *Saisie des informations familiales sur l'application mobile.*

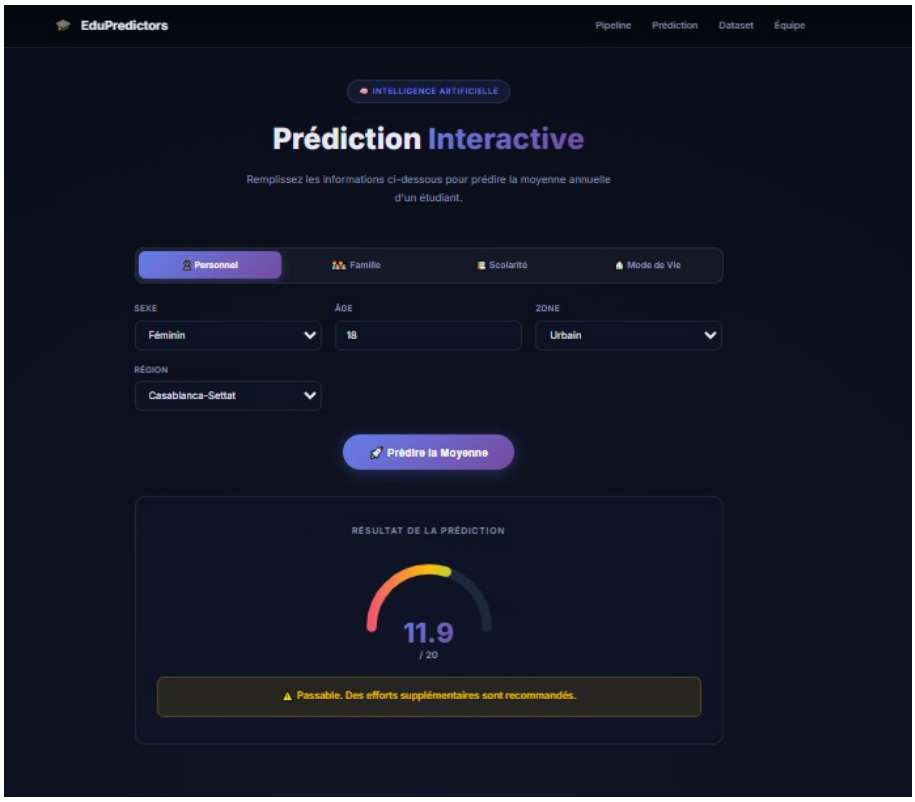

Figure 7.16 – *Saisie des données académiques et scolaires sur l'application mobile.*

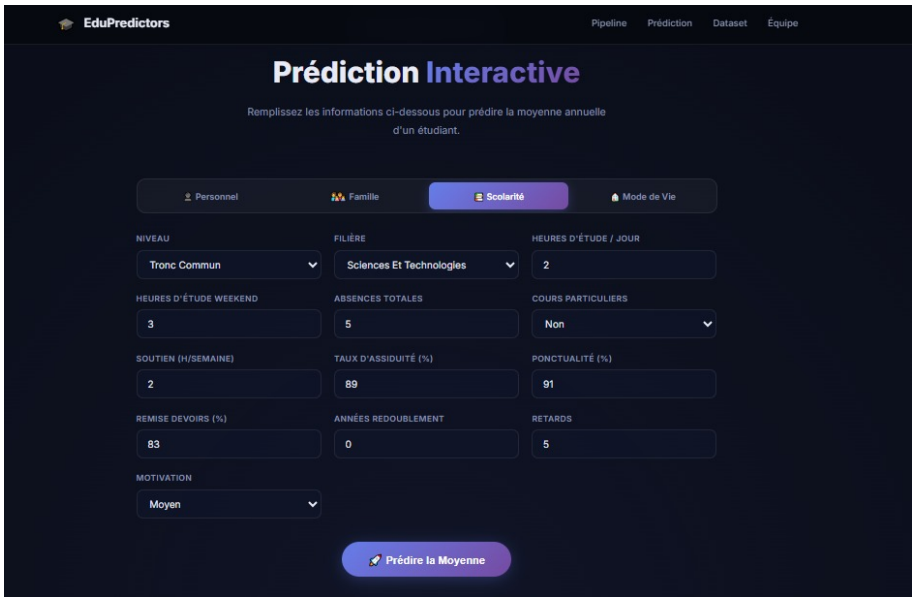

Figure 7.17 – *Validation du formulaire avant soumission sur l'application mobile.*

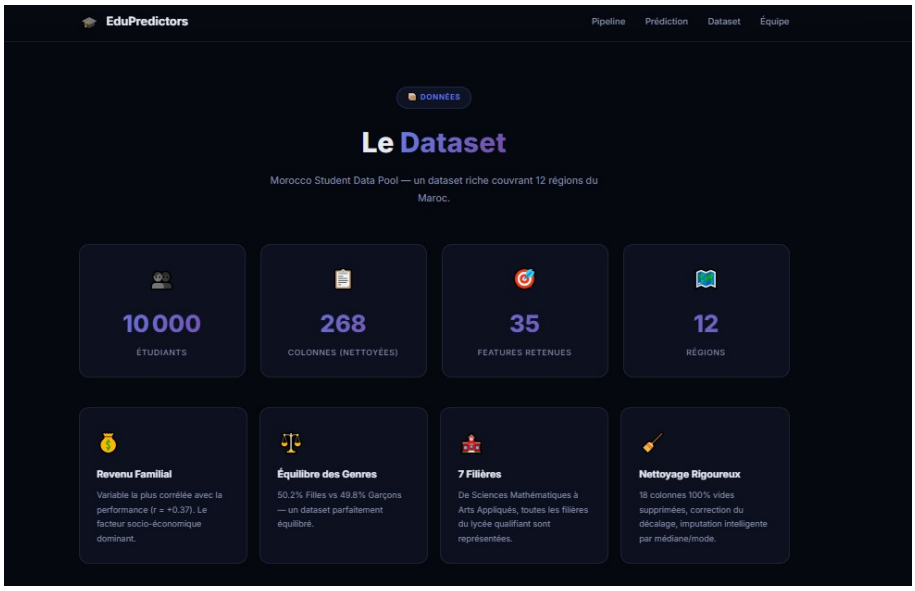

Figure 7.18 – *Écran de chargement pendant l'analyse par l'API Flask sur l'application mobile.*

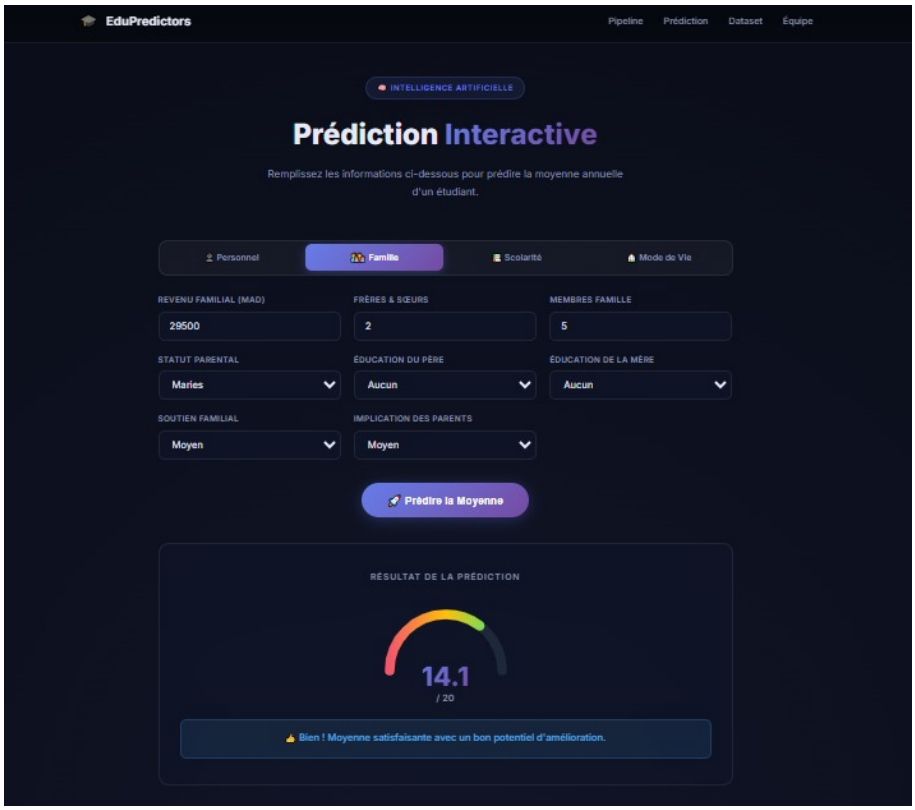

Figure 7.19 – *Affichage du résultat de la prédiction via la jauge de performance.*

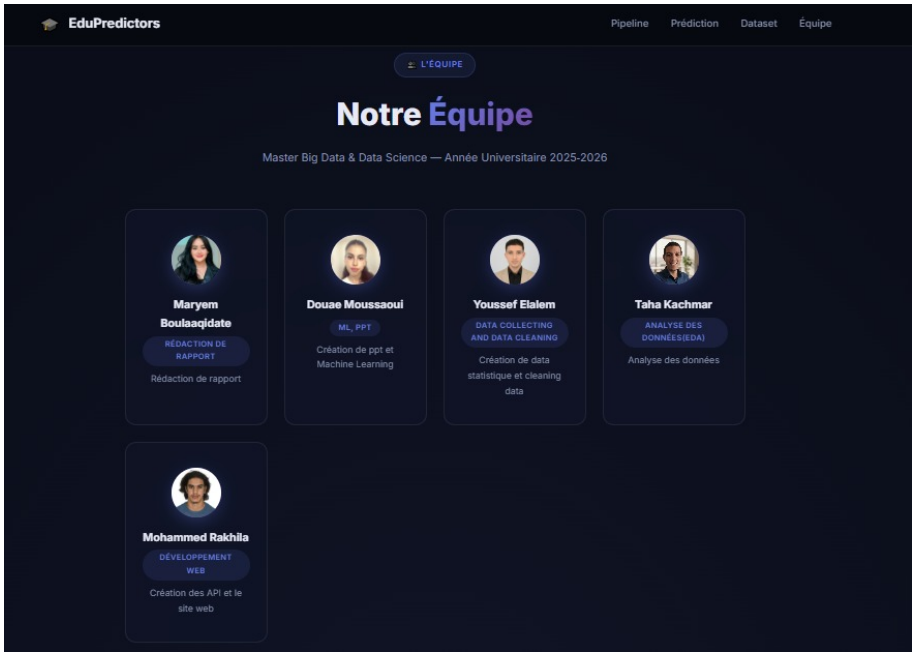

Figure 7.20 – *Page de recommandations personnalisées en fonction du score prédit.*

Chapitre 8

Conclusion générale et perspectives

8.1 Bilan du Projet

Ce projet a permis de concevoir et de déployer un **pipeline complet de Machine Learning**, allant de la collecte de données brutes jusqu'à la mise en production d'une solution logicielle fonctionnelle. L'analyse de 10 000 profils d'étudiants a démontré l'efficacité de l'apprentissage automatique, et plus particulièrement de l'algorithme **Gradient Boosting Tuné** ($R^2 = 0{,}9285$), pour prédire avec précision la performance académique et identifier les élèves présentant un risque de décrochage ou de sous-performance.

L'un des enseignements majeurs de cette étude est la prédominance des facteurs socio-économiques sur la réussite scolaire. L'analyse via les **SHAP Values** a confirmé que le revenu familial est le prédicteur le plus influent, soulignant que la réussite est souvent un mélange complexe entre les moyens financiers disponibles et l'effort personnel, tel que l'assiduité et le temps d'étude. Le **Feature Engineering** (création de variables calculées comme le revenu par personne et l'indice de discipline) a joué un rôle déterminant dans l'atteinte de ces performances élevées.

8.2 Perspectives d'Avenir

Avec un R^2 de **0,9285**, les résultats actuels sont très satisfaisants. Néanmoins, plusieurs pistes d'amélioration ont été identifiées pour aller encore plus loin :

- **Intégration de données longitudinales :** Un suivi des cohortes d'élèves sur plusieurs années permettrait de capturer les dynamiques d'évolution et de détecter les tendances de décrochage sur le long terme.
- **Généralisation à d'autres niveaux :** Étendre le modèle aux élèves du collège et du supérieur pour couvrir l'ensemble du parcours éducatif marocain.
- **Enrichissement qualitatif :** L'ajout de variables liées à la qualité de l'enseignement, aux infrastructures scolaires ou à l'environnement pédagogique permettrait d'affiner les prédictions en intégrant le contexte de l'établissement.
- **Système d'alerte en temps réel :** Intégrer le modèle dans les systèmes d'information des établissements pour générer automatiquement des alertes lorsqu'un élève est détecté à risque, permettant une intervention préventive.