

Rapport d'Analyse Exploratoire des Données (EDA)

Prédiction de la Performance des Étudiants Marocains

Jeu de données	Morocco_Student_Data_Cleaned.csv
Nombre d'observations	10 000 étudiants
Nombre de variables	269 colonnes
Notebook source	EDA_Advanced.ipynb

8 février 2026

Table des matières

1	Introduction et Vue d'ensemble	3
1.1	Caractéristiques du jeu de données	3
2	Qualité des données	3
2.1	Valeurs manquantes	3
2.2	Doublons	4
3	Variables cibles	4
3.1	Description des variables cibles	5
3.2	Analyse de <code>performance_cible</code> (numérique)	5
3.3	Analyse de <code>probabilite_reussite</code> (catégorielle)	5
4	Distribution des variables	6
4.1	Variables catégorielles principales	6
4.2	Variable cible principale : <code>moyenne_annuelle</code>	7
5	Analyse de l'asymétrie (Skewness)	7
5.1	Variables fortement asymétriques	8
6	Détection des valeurs aberrantes (Outliers)	8
7	Analyse des corrélations	9
7.1	Corrélations avec la variable cible <code>moyenne_annuelle</code>	10
7.2	Heatmap de corrélation	11
7.3	Interprétation des corrélations	12
7.3.1	Variables fortement corrélées positivement ($r > 0,9$)	12
7.3.2	Variables fortement corrélées négativement ($r < -0,7$)	12
7.3.3	Variables faiblement corrélées	12
8	Analyse bivariée	12
8.1	Variables numériques vs. <code>moyenne_annuelle</code>	13
8.2	Variables catégorielles vs. <code>moyenne_annuelle</code>	14
9	Analyse croisée (Cross-Tabulation)	14
9.1	Sexe × Probabilité de réussite	15
9.2	Zone × Probabilité de réussite	15
9.3	Niveau scolaire × Probabilité de réussite	15
10	Synthèse et recommandations	16
10.1	Résumé des constats principaux	16
10.2	Recommandations pour la modélisation	16
10.2.1	1. Nettoyage préalable	16
10.2.2	2. Gestion de la fuite de données (Data Leakage)	17
10.2.3	3. Ingénierie des features (Feature Engineering)	17
10.2.4	4. Rééquilibrage des classes (pour la classification)	17
10.2.5	5. Traitement des outliers	17
10.2.6	6. Modèles recommandés	17

11 Annexe : Erreurs détectées et corrections apportées

17

1 Introduction et Vue d'ensemble

Ce rapport présente les résultats détaillés de l'analyse exploratoire des données (EDA) effectuée sur le jeu de données **Morocco_Student_Data_Cleaned.csv**. L'objectif principal est de comprendre la structure des données, détecter les anomalies, identifier les variables les plus pertinentes et préparer le terrain pour la phase de modélisation prédictive.

1.1 Caractéristiques du jeu de données

TABLE 1 – Vue d'ensemble du jeu de données

Caractéristique	Valeur
Nombre de lignes (observations)	10 000
Nombre de colonnes (variables)	269
Variables numériques (<code>float64</code>)	50
Variables numériques (<code>int64</code>)	48
Variables catégorielles (<code>object</code>)	171
Total variables numériques	98
Total variables catégorielles	171

Le jeu de données est **riche et multidimensionnel**, couvrant des informations académiques, sociodémographiques, comportementales, familiales et institutionnelles pour chaque étudiant.

2 Qualité des données

2.1 Valeurs manquantes

L'analyse révèle que **262 colonnes sur 269 sont complètes** (aucune valeur manquante). Seules **7 colonnes** présentent des données incomplètes :

TABLE 2 – Colonnes avec valeurs manquantes

Variable	Nb manquantes	Pourcentage (%)
prise_notes	10 000	100,00
date_collecte	10 000	100,00
pays_cible	8 344	83,44
établissement_precedent	5 925	59,25
niveau_allemand	2 953	29,53
type_travail	2 239	22,39
type_maladie	2 204	22,04




FIGURE 1 – Visualisation des colonnes avec valeurs manquantes

Interprétation :

- **prise_notes** et **date_collecte** sont **entièlement vides** (100%) et doivent être **supprimées**.
- **pays_cible** (83,44%) : concerne probablement les étudiants souhaitant poursuivre leurs études à l'étranger. Le taux élevé de données manquantes est logique car seule une minorité est concernée.
- **etablissement_precedent** (59,25%) : information historique non renseignée pour les étudiants sans transfert.
- **niveau_allemand** (29,53%) : langue optionnelle, les valeurs manquantes correspondent aux étudiants n'apprenant pas l'allemand.
- **type_travail** (22,39%) et **type_maladie** (22,04%) : non applicables pour les étudiants ne travaillant pas ou n'ayant pas de maladie chronique.

2.2 Doublons

La vérification des doublons a été effectuée selon trois critères :

TABLE 3 – Résultats de la vérification des doublons

Critère de vérification	Nombre de doublons
Lignes entièrement dupliquées	0
Doublons sur <code>id_etudiant</code>	0
Doublons sur <code>code_massar</code>	0

✓ **Aucun doublon détecté.** Le jeu de données contient bien 10 000 observations uniques.

3 Variables cibles

Le jeu de données contient trois variables cibles, chacune représentant un aspect différent de la performance de l'étudiant :

3.1 Description des variables cibles

TABLE 4 – Variables cibles du jeu de données

Variable	Type	Description
moyenne_annuelle	Numérique continue	Variable cible principale pour la régression. Représente la note moyenne annuelle de l'étudiant (échelle 0–20).
performance_cible	Numérique continue	Score dérivé de la moyenne annuelle (entre 0,08 et 0,99). À exclure des features car dérivée de la cible.
probabilite_reussite	Catégorielle	Classification en 4 niveaux de probabilité de réussite. Utilisable pour la classification.

3.2 Analyse de performance_cible (numérique)

- **Type :** float64 – variable continue
- **Nombre de valeurs uniques :** 90 (entre 0,08 et 0,99)
- **Moyenne :** 0,41 **Médiane :** 0,41 **Écart-type :** 0,19
- **Distribution :** Légèrement asymétrique à droite (positive skewness)
- **Corrélation avec moyenne_annuelle :** $r = 0,936$ – corrélation très forte

3.3 Analyse de probabilite_reussite (catégorielle)

TABLE 5 – Distribution de la variable probabilite_reussite

Classe	Effectif	Pourcentage (%)
Élevé	6 508	65,1
Moyen	2 707	27,1
Faible	718	7,2
Très Faible	67	0,7

Constat important : Le jeu de données présente un **déséquilibre de classes significatif**. La classe *Élevé* représente 65,1% des observations tandis que la classe *Très Faible* ne compte que 67 individus (0,7%). Des techniques de rééquilibrage (SMOTE, sous-échantillonnage) seront nécessaires pour la classification.




FIGURE 2 – Analyse de la variable cible : distribution de `performance_cible` (gauche), équilibre des classes de `probabilite_reussite` (centre), et relation entre les deux (droite)

4 Distribution des variables

4.1 Variables catégorielles principales




FIGURE 3 – Distribution des 9 principales variables catégorielles

Les observations clés sur les variables catégorielles :

- **Sexe** : Distribution quasi équilibrée – Féminin : 5 017 (50,2%), Masculin : 4 983 (49,8%).

- **Zone** : Prédominance urbaine – Urbain : 5 072 (50,7%), Semi-Urbain : 3 133 (31,3%), Rural : 1 795 (18,0%).
- **Niveau scolaire** : Répartition assez homogène – 2BAC : 3 389 (33,9%), Tronc Commun : 3 283 (32,8%), 1BAC : 3 328 (33,3%).
- **Région** : Couverture de 12 régions du Maroc, avec Casablanca-Settat comme la plus représentée.

4.2 Variable cible principale : moyenne_annuelle




FIGURE 4 – Distribution et boxplot de la variable moyenne_annuelle

TABLE 6 – Statistiques descriptives de moyenne_annuelle

Statistique	Valeur
Moyenne	12,46
Médiane	12,42
Écart-type	2,24
Minimum	7,32
1 ^{er} quartile (Q1)	10,73
3 ^e quartile (Q3)	14,13
Maximum	19,51

La distribution est **approximativement symétrique** ($\text{skewness} \approx 0,13$), légèrement étalée vers la droite. La moyenne et la médiane sont très proches, confirmant une distribution quasi-normale. Cela est favorable pour les modèles de régression linéaire.

5 Analyse de l'asymétrie (Skewness)

L'asymétrie mesure le degré de déformation de la courbe de distribution par rapport à la loi normale. Une variable est considérée fortement asymétrique lorsque $|\text{skewness}| > 1$.

5.1 Variables fortement asymétriques

L'analyse identifie **8 variables** avec une asymétrie prononcée :

TABLE 7 – Variables avec $|skewness| > 1$

Variable	Asymétrie (Skewness)	Aplatissement (Kurtosis)
montant_tayssir	1,577	0,546
annees_redoublement	1,484	0,202
revenu_mensuel_mere	1,446	3,536
heures_travail_semaine	1,373	0,636
absences_non_justifiees	1,327	1,771
revenu_mensuel_pere	1,306	2,611
cout_mensuel_soutien	1,116	0,280
revenu_familial	1,113	2,205




FIGURE 5 – Asymétrie de toutes les variables numériques. Les barres rouges indiquent les variables dépassant le seuil $|skewness| > 1$.

Interprétation :

- Toutes les 8 variables ont une **asymétrie positive** (queue étalée vers la droite), ce qui signifie qu'il y a une concentration de valeurs faibles avec quelques valeurs élevées exceptionnelles.
- Les variables liées aux **revenus** (**revenu_familial**, **revenu_mensuel_pere**, **revenu_mensuel_mere**) sont naturellement asymétriques – c'est un phénomène classique en sciences sociales.
- revenu_mensuel_mere** présente le **kurtosis le plus élevé** (3,536), indiquant des queues de distribution lourdes (valeurs extrêmes).
- Recommandation** : Envisager une transformation logarithmique ($\log(x + 1)$) ou de Box-Cox pour ces variables avant la modélisation.

6 Détection des valeurs aberrantes (Outliers)

La détection des outliers a été réalisée avec la méthode de l'intervalle interquartile (IQR). Un point est considéré comme aberrant si $x < Q_1 - 1,5 \times IQR$ ou $x > Q_3 + 1,5 \times IQR$.

TABLE 8 – Résumé des valeurs aberrantes par variable

Variable	Nb outliers	%	Borne inf.	Borne sup.
revenu_familial	214	2,14	-6 019,75	32 880,25
moyenne_s1	4	0,04	5,55	19,28
moyenne_annuelle	1	0,01	5,51	19,32
moyenne_s2	1	0,01	5,49	19,33
age	0	0,00	14,00	22,00
absences_totales	0	0,00	-18,50	33,50
heures_etude_jour	0	0,00	-1,80	7,80
distance_ecole_km	0	0,00	-8,05	25,95
imc	0	0,00	11,75	34,55




FIGURE 6 – Boxplot comparatif des variables clés après normalisation Min-Max

Constat principal :

- **revenu_familial** est la **seule variable significativement affectée** par les outliers avec 214 observations (2,14%) au-delà de la borne supérieure de 32 880,25 DH.
- Les variables académiques (**moyenne_s1, moyenne_annuelle, moyenne_s2**) ont un nombre **négligeable** d'outliers (< 0,05%).
- Les variables **age, absences_totales, heures_etude_jour, distance_ecole_km** et **imc** ne présentent **aucun outlier** selon la méthode IQR.
- **Recommandation :** Traiter les outliers de **revenu_familial** par *winsorisation* ou transformation logarithmique.

7 Analyse des corrélations

7.1 Corrélations avec la variable cible `moyenne_annuelle`

TABLE 9 – Top 15 des corrélations positives avec `moyenne_annuelle`

Variable	Coefficient de corrélation (r)
<code>moyenne_s2</code>	0,991
<code>moyenne_s1</code>	0,991
<code>moyenne_annee precedente</code>	0,958
<code>performance_cible</code>	0,936
<code>francais_annuel</code>	0,918
<code>education_physique_annuel</code>	0,918
<code>physique_chimie_annuel</code>	0,918
<code>maths_annuel</code>	0,917
<code>svt_annuel</code>	0,917
<code>anglais_annuel</code>	0,915
<code>education_islamique_annuel</code>	0,914
<code>informatique_annuel</code>	0,913
<code>arabe_annuel</code>	0,913
<code>histoire_geo_annuel</code>	0,911
<code>philosophie_annuel</code>	0,910

TABLE 10 – Corrélations négatives notables avec `moyenne_annuelle`

Variable	Coefficient de corrélation (r)
<code>nombre_membres_famille</code>	-0,020
<code>poids_kg</code>	-0,025
<code>age</code>	-0,039
<code>montant_tayssir</code>	-0,146
<code>rang_annee precedente</code>	-0,771
<code>rang_s2</code>	-0,823
<code>rang_s1</code>	-0,847
<code>rang_annuel</code>	-0,847




FIGURE 7 – Top 15 des corrélations positives (gauche) et top 10 des corrélations négatives (droite) avec moyenne_annuelle

7.2 Heatmap de corrélation




FIGURE 8 – Matrice de corrélation (heatmap) des 15 variables les plus corrélées avec moyenne_annuelle

7.3 Interprétation des corrélations

7.3.1 Variables fortement corrélées positivement ($r > 0,9$)

1. **moyennes semestrielles** ($r = 0,991$) : `moyenne_s1` et `moyenne_s2` sont très fortement corrélées car la `moyenne_annuelle` est leur moyenne arithmétique. **Risque de fuite de données (data leakage)**.
2. **moyenne année précédente** ($r = 0,958$) : forte continuité dans la performance académique d'une année à l'autre. **Variable dérivée – à évaluer soigneusement.**
3. **performance_cible** ($r = 0,936$) : variable directement dérivée de `moyenne_annuelle`. **Doit être exclue des features.**
4. **Notes annuelles par matière** ($r \approx 0,91\text{--}0,92$) : les notes de français, éducation physique, physique-chimie, maths, SVT, anglais, etc., sont les **composantes directes** de la moyenne. **Variable dérivée – à exclure pour éviter la fuite.**

7.3.2 Variables fortement corrélées négativement ($r < -0,7$)

Les variables de **classement** (`rang_annuel`, `rang_s1`, `rang_s2`) montrent une forte corrélation négative avec la moyenne : plus la moyenne est élevée, meilleur est le rang (plus petit en valeur). Ces variables sont **redondantes** car elles sont une transformation directe de la moyenne.

7.3.3 Variables faiblement corrélées

Les variables `nombre_membres_famille` ($r = -0,020$), `poids_kg` ($r = -0,025$) et `age` ($r = -0,039$) n'ont **pratiquement aucune corrélation linéaire** avec la performance académique when considérées isolément.

△ Alerte – Risque de fuite de données (Data Leakage) :

Les variables suivantes sont **dérivées** de `moyenne_annuelle` et ne doivent **pas** être utilisées comme features dans le modèle prédictif :

- `moyenne_s1`, `moyenne_s2` (composantes de la moyenne)
- `performance_cible` (transformation directe)
- `rang_annuel`, `rang_s1`, `rang_s2` (classement basé sur la moyenne)
- Toutes les notes annuelles par matière (`*_annuel`)

8 Analyse bivariée

8.1 Variables numériques vs. moyenne_annuelle




FIGURE 9 – Nuages de points des variables numériques en fonction de `moyenne_annuelle`, colorés par sexe avec ligne de tendance

Observations :

- `performance_cible` montre une relation linéaire **très forte** avec `moyenne_annuelle` (confirmation de la corrélation $r = 0,936$), car il s'agit d'une variable dérivée.
- `absences_totales` ne montre **pas de relation linéaire claire** avec la moyenne. La dispersion est uniforme, ce qui suggère que les absences seules ne suffisent pas à expliquer la performance.
- `heures_etude_jour` présente une dispersion **homogène**, sans tendance marquée.
- `revenu_familial` montre une relation **quasi inexiste**ante avec la moyenne annuelle.
- Aucune différence visible entre les sexes dans les nuages de points.

8.2 Variables catégorielles vs. moyenne_annuelle




FIGURE 10 – Boxplots montrant l’impact des variables catégorielles sur moyenne_annuelle. La ligne rouge horizontale représente la moyenne globale.

Observations :

- **Sexe :** Les distributions sont **quasi identiques** entre les garçons et les filles, confirmant l’absence de biais de genre dans les performances académiques.
- **Zone :** Les médianes sont **très similaires** entre les zones urbaine, semi-urbaine et rurale.
- **Région :** Quelques variations entre les 12 régions, mais les différences restent **modestes**.
- **Niveau scolaire :** Les 3 niveaux (Tronc Commun, 1BAC, 2BAC) montrent des distributions **comparables**.
- **Type d’établissement :** Différence **minimale** entre les types.
- **Statut parental :** Distribution **homogène**, le statut marital des parents n’influence pas significativement la moyenne.

9 Analyse croisée (Cross-Tabulation)

Les tableaux croisés examinent la relation entre les variables catégorielles et la variable **probabilite_reussite**.

9.1 Sexe × Probabilité de réussite

TABLE 11 – Tableau croisé : Sexe × Probabilité de réussite (%)

Sexe	Élevé	Faible	Moyen	Très Faible
Féminin (F)	65,2	6,9	27,3	0,6
Masculin (M)	64,9	7,5	26,9	0,7
Total	65,1	7,2	27,1	0,7

Constat : Les proportions sont **quasi identiques** entre les sexes. Le sexe de l'étudiant ne semble pas être un facteur discriminant pour la probabilité de réussite.

9.2 Zone × Probabilité de réussite

TABLE 12 – Tableau croisé : Zone × Probabilité de réussite (%)

Zone	Élevé	Faible	Moyen	Très Faible
Rural	68,3	6,2	24,9	0,6
Semi-Urbain	65,2	7,3	26,9	0,6
Urbain	63,9	7,5	27,9	0,7

Constat : Étonnamment, les étudiants en zone **rurale** présentent un taux légèrement plus élevé de probabilité “Élevée” (68,3% vs 63,9% en urbain). Cela pourrait être un artefact des données synthétiques ou refléter un effet de sélection.

9.3 Niveau scolaire × Probabilité de réussite

TABLE 13 – Tableau croisé : Niveau × Probabilité de réussite (%)

Niveau	Élevé	Faible	Moyen	Très Faible
1BAC	66,6	7,2	25,7	0,6
2BAC	64,0	7,5	27,8	0,7
Tronc Commun	64,7	6,9	27,7	0,7

Constat : Les distributions sont **très homogènes** entre les trois niveaux scolaires. Le niveau d'études n'est pas un facteur fortement discriminant.




FIGURE 11 – Distribution de la probabilité de réussite par sexe, zone et niveau scolaire

10 Synthèse et recommandations

10.1 Résumé des constats principaux

TABLE 14 – Synthèse des résultats de l’EDA

Aspect	Constat
Taille	10 000 observations \times 269 variables (98 numériques, 171 catégorielles)
Qualité	Très bonne. Seulement 7/269 colonnes avec valeurs manquantes. 0 doublon.
Variable cible	<code>moyenne_annuelle</code> (régression) : distribution quasi-normale, $\mu = 12,46$, $\sigma = 2,24$
Déséquilibre	<code>probabilite_reussite</code> : classe <i>Élevé</i> = 65,1%, classe <i>Très Faible</i> = 0,7%
Corrélations	Variables dérivées très corrélées ($r > 0,9$). Variables socio-économiques faiblement corrélées.
Asymétrie	8 variables avec $ skewness > 1$ (revenus, absences, Tayssir)
Outliers	Significatifs uniquement pour <code>revenu_familial</code> (2,14%)
Discrimination	Sexe, zone et niveau ont un impact minimal sur la performance

10.2 Recommandations pour la modélisation

10.2.1 1. Nettoyage préalable

- **Supprimer** les colonnes `prise_notes` et `date_collecte` (100% manquantes).
- **Supprimer** les colonnes identifiantes : `id_etudiant`, `prenom`, `nom`, `nom_complet`, `code_massar`, `telephone`.

- **Supprimer** les variables à valeur unique : `annee_inscription`, `intervention_necessaire`, `id_collecteur`, `statut_verification`.

10.2.2 2. Gestion de la fuite de données (Data Leakage)

- **Exclure impérativement** des features : `moyenne_s1`, `moyenne_s2`, `performance_cible`, `rang_annuel`, `rang_s1`, `rang_s2`, `rang_annee precedente`, et toutes les notes annuelles par matière (`*_annuel`).
- **Évaluer soigneusement** : `moyenne_annee precedente` (informative mais potentiellement dérivée).

10.2.3 3. Ingénierie des features (Feature Engineering)

- **Transformation logarithmique** : appliquer $\log(x+1)$ aux variables à forte asymétrie (`revenu_familial`, `revenu_mensuel_pere`, `revenu_mensuel_mere`, `montant_tayssir`).
- **Encodage** : One-Hot Encoding pour les variables catégorielles à faible cardinalité, Label Encoding ou Target Encoding pour celles à haute cardinalité.
- **Binning de l'âge** : regrouper en catégories (17, 18, 19) si nécessaire.
- **Nouvelles variables** : ratio revenus/membres de famille, taux d'absences justifiées, interaction heures d'étude × participation aux cours de soutien.

10.2.4 4. Rééquilibrage des classes (pour la classification)

- Appliquer **SMOTE** (Synthetic Minority Over-sampling Technique) pour augmenter les classes minoritaires.
- Ou utiliser un **sous-échantillonnage stratifié** de la classe majoritaire.
- Utiliser des **poids de classe** dans les algorithmes supportant cette fonctionnalité.

10.2.5 5. Traitement des outliers

- **Winsorisation** de `revenu_familial` au 95^e percentile.
- Conserver les outliers modérés des variables académiques (peu nombreux).

10.2.6 6. Modèles recommandés

- **Régression** : Random Forest Regressor, Gradient Boosting (XGBoost/LightGBM), Ridge/Lasso pour la prédiction de `moyenne_annuelle`.
- **Classification** : Random Forest Classifier, XGBoost Classifier, SVM pour la prédiction de `probabilite_reussite`.
- **Baseline** : Régression linéaire et Logistic Regression pour établir des performances de référence.

11 Annexe : Erreurs détectées et corrections apportées

Lors de la revue de l'EDA originale, **6 erreurs** ont été identifiées et corrigées dans le notebook `EDA_Advanced.ipynb`. Les corrections suivantes ont été appliquées pour garantir la fiabilité des résultats :

TABLE 15 – Erreurs détectées et corrections apportées au notebook

#	Erreur originale	Correction appliquée
1	performance_cible décrite comme catégorielle	Corrigé : c'est une variable numérique continue (float64, 90 valeurs uniques)
2	probabilite_reussite décrite comme numérique	Corrigé : c'est une variable catégorielle (4 classes)
3	Corrélation calculée par rapport à probabilite_reussite (catégorielle ⇒ résultats incorrects)	Corrigé : corrélation calculée par rapport à moyenne_annuelle
4	Analyse bivariée utilisant performance_cible comme cible	Corrigé : utilisation de moyenne_annuelle comme cible
5	Tableau croisé avec performance_cible (90 valeurs float = tableaux illisibles)	Corrigé : utilisation de probabilite_reussite (4 catégories)
6	Pair plot avec hue = performance_cible (dégradé incohérent)	Corrigé : hue = probabilite_reussite

Fin du rapport – Analyse Exploratoire des Données (EDA)

Données : Morocco_Student_Data_Cleaned.csv | Source : EDA_Advanced.ipynb